GUSTAVO DE MELO NASCIMENTO

RA 239679

Previsão multirresolução de irradiância global horizontal em localidades associadas à fabricação de veículos elétricos

Avaliação comparativa de Transformer, Informer e LSTM

Link do vídeo: _____

CAMPINAS

2026

Previsão multirresolução de irradiância global horizontal em localidades associadas à fabricação de veículos elétricos

Avaliação comparativa de Transformer, Informer e LSTM

Trabalho apresentado como requisito para conclusão do curso de ENGENHARIA ELÉTRICA da Universidade Estadual de Campinas, no âmbito da disciplina EA019, orientado pelo Prof. Dr. Gustavo Fraidenraich.

Aluno: Gustavo de Melo Nascimento

RA: 239679

Curso: Engenharia Elétrica (41)

Disciplina: EA019

Semestre: 2º semestre de 2026

Professor orientador: Gustavo Fraidenraich

Coorientador: Thales Wulfert Cabral

CAMPINAS

2026

Dedico este trabalho a todos que contribuíram para a minha formação e incentivaram minha trajetória de aprendizado.

Agradecimentos

Agradeço ao Prof. Dr. Gustavo Fraidenraich, pela orientação, e ao coorientador Thales Wulfert Cabral, pelas contribuições ao desenvolvimento deste trabalho.

Agradeço também aos professores e colegas da Faculdade de Engenharia Elétrica e de Computação da Universidade Estadual de Campinas que fizeram parte da minha formação acadêmica.

SUMÁRIO

1 INTRODUÇÃO 7
1.1 Questões de pesquisa 7
2 OBJETIVOS 8
2.1 Objetivo geral 8
2.2 Objetivos específicos 8
2.3 Delimitação do estudo 8
3 METODOLOGIA 9
3.1 Dados utilizados 9
3.2 Resoluções temporais da GHI 10
3.3 Tarefas e janelas temporais 11
3.4 Separação cronológica e comparação pareada 12
3.5 Normalização e condições de entrada 13
3.6 Treinamento, seleção e refit 15
3.7 Análise dos dados e métricas 15
4 DESENVOLVIMENTO 17
4.1 Fundamentos físicos da GHI 17
4.2 LSTM e memória temporal 17
4.3 Transformer e atenção 17
4.4 Informer e atenção esparsa 18
4.5 Trabalhos relacionados e posicionamento 19
5 RESULTADOS 21
5.1 Desempenho no teste de 2024 21
5.2 Heterogeneidade entre localidades 22
5.3 Comportamento nos horizontes cumulativos 23
5.4 Quantização como análise de pré-processamento 24
5.5 Análise complementar da duração do histórico 26
5.6 Diagnóstico dos registros de treinamento 27
5.7 Discussão integrada e limitações 28
6 CONCLUSÃO 30
7 REFERÊNCIAS BIBLIOGRÁFICAS 31
APÊNDICE A — RESULTADOS POR HORIZONTE NO REGIME ATUAL 32
APÊNDICE B — COMPARAÇÃO DAS QUATRO CONDIÇÕES DE ENTRADA 34
B.1 Atual 34
B.2 Histórico longo 34
B.3 Histórico curto 35
APÊNDICE C — CONFIGURAÇÕES DAS IMPLEMENTAÇÕES 36
C.1 Configurações e parâmetros treináveis 36
C.2 Ambiente das execuções 37

RESUMO

Este trabalho compara o desempenho de Transformer, Informer e LSTM na previsão multirresolução de irradiância global horizontal (GHI). São utilizadas estimativas da National Solar Radiation Database em dez localidades associadas à fabricação de veículos elétricos no Brasil, nos Estados Unidos e no México. O protocolo compreende previsão horária de até 72 horas, diária de até 30 dias e mensal de um e seis passos, sendo a última exploratória. As redes recebem o histórico de GHI e a identidade da localidade, com separação cronológica entre ajuste, validação e teste. A quantização das entradas em 64, 128 e 256 níveis é avaliada como opção de pré-processamento frente ao controle contínuo. Épocas e condição de entrada são selecionadas na validação. O erro absoluto médio (MAE) é calculado por localidade e agregado com pesos iguais.

Nas configurações selecionadas para o teste de 2024, o Transformer apresentou os menores MAEs cumulativos nos horizontes completos horário e diário, de 53,21 e 43,89 W/m². O Informer liderou as tarefas mensais, com 12,73 W/m² em um passo e 13,67 W/m² em seis passos. A ordenação dos três modelos nesses horizontes completos foi a mesma sob entradas contínuas comuns, embora varie entre localidades e horizontes menores. Como análises complementares, as condições quantizadas selecionadas reduziram o MAE em cinco combinações de modelo e tarefa e o elevaram em quatro; nas três restantes, foi escolhido o controle. O histórico longo reduziu o erro do controle em onze das doze comparações pareadas. Os resultados descrevem a precisão preditiva das implementações avaliadas. A transformação quantizada inclui clipping e arredondamento, sem mensuração de compressão, aceleração computacional ou produção fotovoltaica.

Palavras-chave: irradiância global horizontal; previsão multirresolução; comparação de modelos; Transformer; Informer; LSTM.

1 INTRODUÇÃO

A previsão do recurso solar auxilia o planejamento de sistemas fotovoltaicos e a operação de sistemas elétricos. Os ciclos astronômicos e as variações de nebulosidade produzem comportamentos distintos nas escalas horária, diária e mensal, tornando o desempenho dependente do horizonte e das informações disponíveis no momento da previsão [1]. Neste trabalho, prevê-se a irradiância global horizontal (GHI), expressa em W/m².

O problema central é comparar o desempenho de Transformer, Informer e LSTM na previsão de GHI em diferentes resoluções e horizontes temporais. O estudo examina a classificação das três implementações por tarefa, localidade e horizonte, sob regras comuns de preparação e avaliação. Consideram-se tanto entradas contínuas comuns às redes quanto as condições de entrada selecionadas para cada modelo na validação, distinguindo essas duas comparações.

O recorte reúne três mecanismos de representação temporal: memória recorrente na LSTM, atenção completa no Transformer e atenção esparsa no Informer [2,3,4]. A comparação utiliza regras comuns de preparação e avaliação, sem pressupor uma arquitetura superior em todas as tarefas. As redes compartilham parâmetros entre as dez localidades e incorporam sua identidade por um embedding, vetor aprendido durante o treinamento. Essa organização caracteriza uma modelagem global, avaliada nas mesmas localidades incluídas no ajuste [5].

As séries provêm da National Solar Radiation Database (NSRDB), que fornece estimativas do recurso solar por modelagem e sensoriamento remoto [6,7]. As coordenadas de instalações associadas à fabricação de veículos elétricos definem as células geográficas consultadas. Esse contexto motiva a aplicação, mas o objeto avaliado é a GHI; geração fotovoltaica, carga industrial e ganhos econômicos exigiriam dados adicionais.

A representação das entradas integra a configuração de cada modelo. Como análise de apoio, compara-se o histórico normalizado contínuo com sua reconstrução em 64, 128 ou 256 níveis. Essa quantização introduz uma distorção de representação [8] e permite verificar a sensibilidade dos resultados a uma opção de pré-processamento, sem emular um sensor específico. Apenas o histórico de entrada é discretizado; alvos, pesos e saídas permanecem contínuos. A inferência em aritmética inteira com pesos e ativações quantizados, estudada por Jacob et al. [9], constitui uma aplicação distinta.

A contribuição do TCC é oferecer uma comparação reproduzível das três implementações em quatro tarefas de previsão de GHI, identificando como sua ordenação varia entre escalas temporais, horizontes e localidades. A análise das condições de entrada verifica se a escolha do pré-processamento altera essa comparação; o confronto entre históricos pareados examina o comportamento das redes diante da ampliação dos dados de ajuste. Os resultados são vinculados aos dados, às configurações e às versões de código utilizadas.

1.1 Questões de pesquisa

A questão principal é como Transformer, Informer e LSTM se comparam na previsão de GHI, considerando tarefas temporais, horizontes e localidades. Duas questões auxiliares examinam se a seleção de entradas contínuas ou quantizadas altera o desempenho e a ordenação das redes, e como a ampliação do histórico se relaciona com o erro quando validação e teste são mantidos idênticos. A comparação entre modelos orienta a leitura dos resultados; as análises de pré-processamento e duração do histórico contextualizam as diferenças observadas.

2 OBJETIVOS

2.1 Objetivo geral

Comparar o desempenho de Transformer, Informer e LSTM na previsão de irradiância global horizontal em diferentes resoluções e horizontes temporais, utilizando um protocolo comum de avaliação e separação cronológica dos dados.

2.2 Objetivos específicos

Organizar e caracterizar as séries das dez localidades e as tarefas horária, diária e mensais, distinguindo histórico de entrada, horizonte de saída e número de origens de teste.

Comparar os três modelos por tarefa, horizonte e localidade, distinguindo a avaliação sob entradas contínuas comuns daquela que utiliza a condição de entrada selecionada para cada rede na validação.

Selecionar o número de épocas e a condição de entrada na validação e documentar o novo ajuste anterior ao teste, denominado refit, e a combinação das previsões entre sementes.

Analisar MAE, MSE, RMSE, nRMSE e R^2, explicitando suas unidades e formas de agregação, com ênfase no macro-MAE cumulativo.

Investigar, como análise complementar, o desempenho dos modelos com históricos longo e curto sob validação e teste pareados, distinguindo esse confronto da avaliação de 2024.

Avaliar a quantização em 64, 128 e 256 níveis como opção de pré-processamento frente ao controle contínuo, verificando sua influência no erro e na comparação entre os modelos, com resultados rastreáveis em tabelas e figuras.

2.3 Delimitação do estudo

As redes recebem somente o histórico de GHI e a identidade da localidade. Não são utilizadas previsões numéricas do tempo, imagens de nuvens, temperatura de módulos, demanda fabril ou geração fotovoltaica. A avaliação é retrospectiva e pressupõe a disponibilidade do histórico, sem simular atrasos de publicação da NSRDB ou custos de aquisição dos dados.

A comparação se concentra na precisão preditiva das três implementações. A quantização é examinada como opção de pré-processamento do histórico: as entradas discretizadas são reconstruídas em float32, os pesos permanecem contínuos e não se medem memória ou tempo de execução. Os resultados descrevem as implementações e os protocolos utilizados; pequenas diferenças médias não demonstram superioridade estatística nem permitem generalizar a classificação a famílias inteiras de modelos.

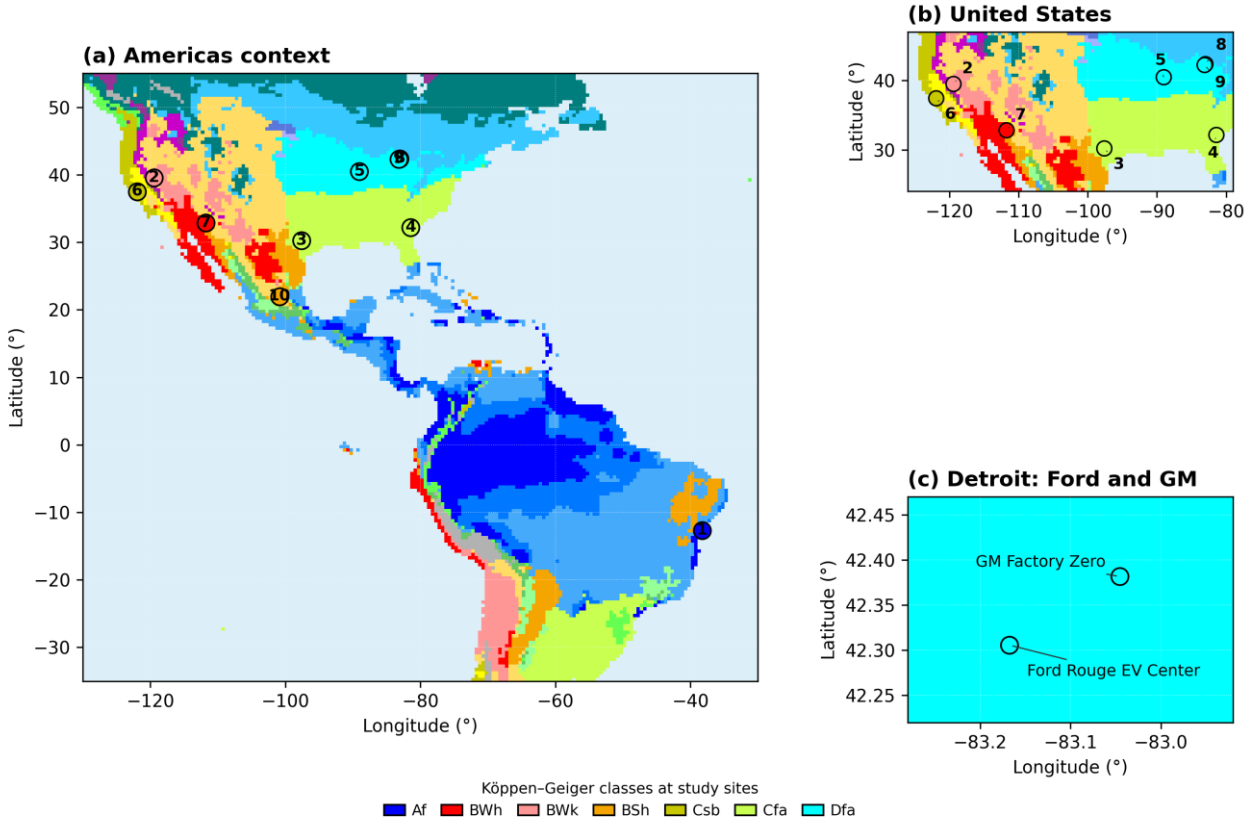
3 METODOLOGIA

3.1 Dados utilizados

A base reúne dez séries de GHI em coordenadas de referência de instalações industriais nas Américas. A Figura 1 mostra sua distribuição geográfica, e a Tabela 1 informa as coordenadas. A seleção intencional reúne contextos distintos, sem representar uma amostra aleatória de fábricas ou climas. Cada coordenada identifica uma célula da NSRDB, e não um sensor instalado na unidade industrial.

A documentação da API PSM v4 informa resolução espacial nominal de 4 km e registros nativos de 30 minutos, com consultas em intervalos de 30 ou 60 minutos [7]. No projeto, a série horária é formada a partir dos registros de 30 minutos. As médias diárias provêm de uma consulta independente em 60 minutos, e as mensais são médias aritméticas das diárias. Todas conservam a unidade W/m²; contudo, as séries horária e diária não devem ser tratadas como agregações do mesmo conjunto de registros brutos.

Figura 1 — Distribuição geográfica e contexto climático das dez localidades



Fonte: elaboração própria.

Tabela 1 — Localidades e coordenadas de referência

Localidade	País	Latitude	Longitude
BYD Camaçari	BR	−12,6734	−38,2812
Tesla Nevada	EUA	39,5404	−119,4391
Tesla Texas	EUA	30,2219	−97,6188
Hyundai Georgia	EUA	32,1605	−81,4510
Rivian Normal	EUA	40,5093	−89,0545
Tesla Fremont	EUA	37,4927	−121,9415
Lucid Casa Grande	EUA	32,8569	−111,7784
GM Factory Zero	EUA	42,3815	−83,0453
Ford Rouge EV Center	EUA	42,3056	−83,1676
BMW San Luis Potosí	MX	21,9683	−100,8492

Fonte: elaboração própria com dados e registros de execução do projeto (Apêndice C). Coordenadas em graus decimais.

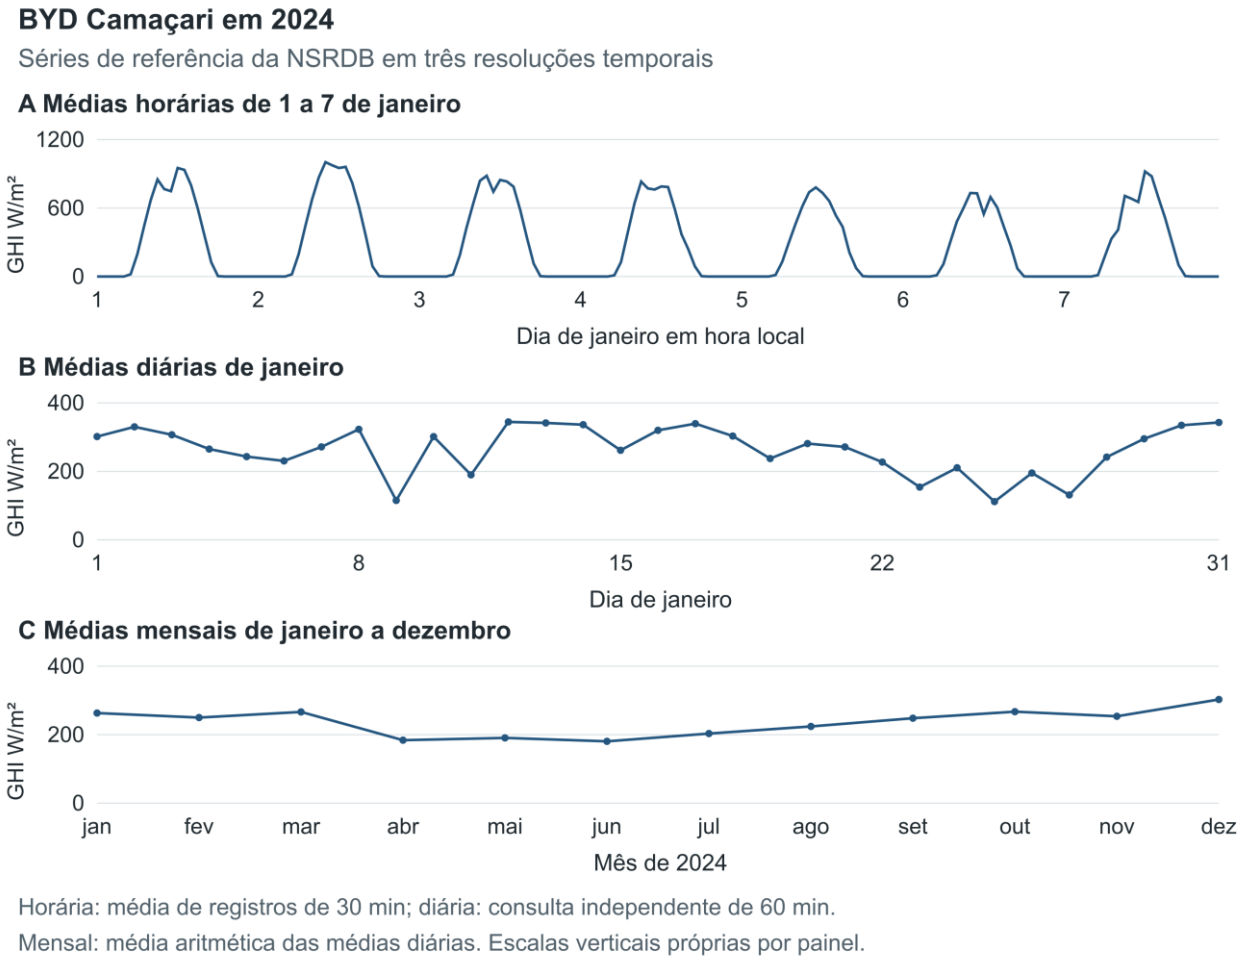
A preparação verifica a coerência temporal e a identidade das localidades. Valores de GHI não finitos ou negativos, datas inválidas, duplicatas e lacunas provocam falha na validação dos dados; registros fora de ordem são reordenados. Não se utiliza preenchimento por interpolação ou inserção de zeros. Cada janela contém apenas observações anteriores à origem da previsão, e todo o vetor de alvos deve pertencer à partição correspondente.

A origem de previsão é o instante em que se emite um vetor de valores futuros. Origens consecutivas podem gerar previsões para os mesmos instantes-alvo, usando históricos diferentes. Por isso, a avaliação preserva cada par de origem e passo previsto: ele representa uma previsão emitida com a informação disponível naquele momento. Essa sobreposição faz o número de previsões superar o de instantes-alvo distintos e introduz dependência entre os erros.

3.2 Resoluções temporais da GHI

A Figura 2 apresenta a GHI de referência de BYD Camaçari em recortes de 2024. A série horária evidencia o ciclo diurno, enquanto as médias diárias e mensais sintetizam a variação em períodos mais longos. Os painéis mantêm a unidade W/m² e ilustram a mudança de estrutura dos dados com a agregação temporal. São perfis da referência utilizada na avaliação, sem previsões dos modelos.

Figura 2 — Perfis de referência da GHI nas resoluções horária, diária e mensal



Fonte: elaboração própria. Séries NSRDB de BYD Camaçari. Semana de 1 a 7 de janeiro, médias diárias de janeiro e médias mensais de 2024. Horária e diária provêm de consultas independentes; a mensal é calculada das diárias. Escalas verticais próprias por painel.

3.3 Tarefas e janelas temporais

Na tarefa horária, emite-se um vetor de 72 previsões uma vez por dia, às 00:00 no horário local fixo informado pela NSRDB, sem aplicação de horário de verão. Assim, o horizonte de saída é de 72 horas, mas o espaçamento entre origens consecutivas é de 24 horas.

Tabela 2 — Contextos de entrada e cobertura efetiva de teste

Tarefa	Contexto C	Saída H	Origens 2024 por local	Origens históricas por local
Horária	336 horas	72 horas	363	1.368
Diária	365 dias	30 dias	337	1.342
Mensal um passo	12 meses	1 mês	12	45
Mensal seis passos	12 meses	6 meses	7	40

Fonte: elaboração própria com dados e registros de execução do projeto (Apêndice C). As contagens históricas são iguais no longo e no curto pareado. O horizonte mensal de seis passos é exploratório.

A Tabela 2 distingue o contexto observado C, o horizonte de saída H e a cobertura efetiva do teste. O histórico horário corresponde a duas semanas; os contextos diário e mensal abrangem aproximadamente um ciclo anual. As redes produzem o vetor futuro diretamente. Na tarefa mensal de seis passos, as avaliações cumulativas de um, três e seis meses utilizam a mesma rede. A tarefa mensal de um passo utiliza uma rede treinada separadamente.

Os horizontes de avaliação são 24, 48 e 72 horas; 1, 3, 7, 14 e 30 dias; um mês na tarefa mensal curta; e 1, 3 e 6 meses na tarefa exploratória. As métricas apresentadas são cumulativas: o MAE de 72 horas, por exemplo, reúne os passos de 1 a 72 de todas as origens válidas, em vez de considerar somente o erro no último instante.

3.4 Separação cronológica e comparação pareada

O protocolo divide os dados em quatro etapas cronológicas. No treino inicial, a rede aprende com a primeira parte do histórico; a validação orienta a escolha do número de épocas e da condição de entrada. Em seguida, o novo ajuste anterior ao teste, denominado refit, reinicia o treinamento com todo o histórico anterior ao teste, incluindo a validação. O teste avalia as escolhas já fixadas. A Tabela 3 apresenta as datas dos regimes atual, histórico longo e histórico curto pareado, e a Figura 3 reúne o fluxo experimental.

Tabela 3 — Regimes temporais de seleção e avaliação

Regime	Histórico inicial	Validação	Refit antes do teste	Teste
Atual	jan 2019 a dez 2022	jan a dez 2023	jan 2019 a dez 2023	jan a dez 2024
Histórico longo	jan 1998 a mar 2018	abr 2018 a mar 2019	jan 1998 a mar 2019	abr 2019 a dez 2022
Histórico curto pareado	abr 2014 a mar 2018	abr 2018 a mar 2019	abr 2014 a mar 2019	abr 2019 a dez 2022

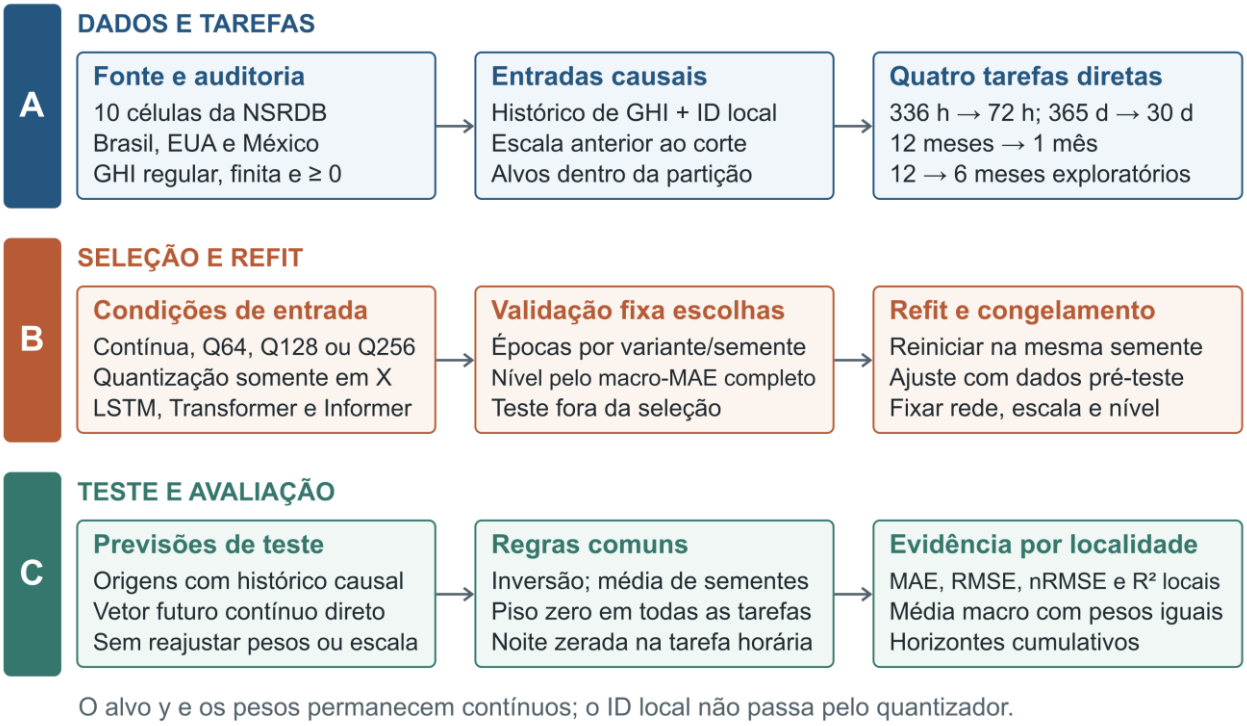
Fonte: elaboração própria com dados e registros de execução do projeto (Apêndice C).

As janelas respeitam os limites da Tabela 3: é necessário dispor do contexto C antes da primeira origem, e todo o horizonte H deve caber na partição avaliada. No regime atual, 2019 fornece o histórico necessário às primeiras janelas diárias e mensais com alvos em 2020. Durante o teste deslizante, observações já disponíveis podem integrar a entrada de uma previsão posterior, enquanto pesos, escalas e condição de entrada permanecem fixos.

Como análise complementar, os regimes longo e curto pareado avaliam a duração do histórico nos mesmos alvos e datas de validação e teste. A diferença está no início do histórico disponível para ajuste. O regime atual testa 2024, outro período; confrontar diretamente seus erros com os históricos misturaria a duração do treinamento com a mudança do período avaliado.

Na tarefa horária histórica, a cobertura em UTC não contém todo o horizonte local da origem de 29 de dezembro de 2022. Essa origem foi excluída dos dois históricos, resultando em 1.368 origens válidas por localidade, conforme a Tabela 2. O procedimento preserva o pareamento sem preencher a janela incompleta.

Figura 3 — Fluxo experimental em etapas de dados, seleção e avaliação



Fonte: elaboração própria.

3.5 Normalização e condições de entrada

A normalização é ajustada separadamente para cada localidade e etapa, usando somente dados anteriores ao respectivo corte. No regime atual, a seleção utiliza dados anteriores a 2023; o refit recalcula a transformação com os dados anteriores a 2024. Nos regimes históricos aplica-se a mesma regra. A Equação 1 transforma x em u, sendo a e b o mínimo e o máximo estimados nesse histórico admissível.

$$u = \frac{x - a}{b - a} \quad (1)$$

As variantes quantizadas aplicam a Equação 2 ao histórico X, com N em {64, 128, 256}. Primeiro, a saturação, ou clipping, limita a entrada ao intervalo de zero a um. Em seguida, a função rint arredonda para o inteiro mais próximo, escolhendo o inteiro par em empates exatos. A Figura 4 ilustra a combinação de saturação e discretização.

$$Q_N(u) = \frac{rint[(N-1)\ clip(u,0,1)]}{N-1} \quad (2)$$

Tabela 4 — Condições de entrada e resolução nominal

Condição	Níveis	Passo normalizado	Erro máximo de arredondamento
Controle	Contínuo	Não se aplica	Não se aplica
Q64	64	0,015873	0,007937
Q128	128	0,007874	0,003937
Q256	256	0,003922	0,001961

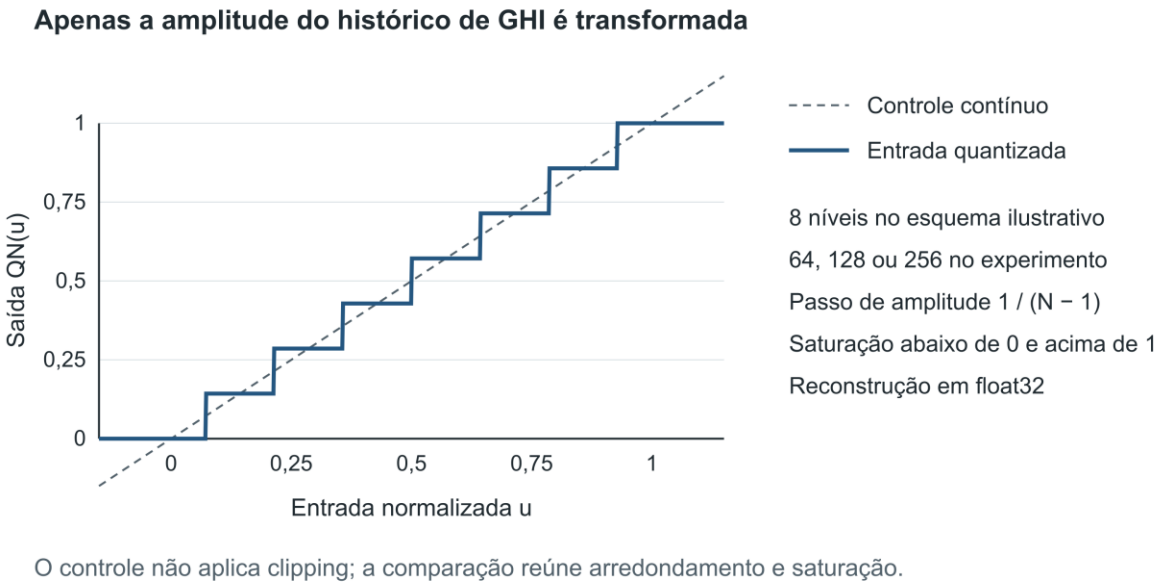
Fonte: elaboração própria com dados e registros de execução do projeto (Apêndice C). O limite vale somente para entradas já contidas em [0,1], antes da conversão float32. Não limita o erro de previsão.

O alvo y também é normalizado, mas não é quantizado. Pesos e saídas permanecem contínuos, e o identificador de localidade não passa pelo quantizador de GHI. Os valores projetados nos níveis são reconstruídos em float32. Embora 64, 128 e 256 símbolos admitam codificações nominais de 6, 7 e 8 bits, o experimento não implementa nem mede essa redução de armazenamento [8,9].

O controle contínuo não aplica clipping. Consequentemente, os contrastes com as variantes quantizadas refletem a combinação de arredondamento e saturação das entradas fora da faixa de ajuste. Um controle adicional com apenas clipping seria necessário para separar os dois efeitos. O limite da Tabela 4 caracteriza somente o arredondamento da entrada, sem limitar o erro de previsão da rede.

Em unidades físicas, o espaçamento entre níveis é $\Delta = (b - a)/(N - 1)$, em que $b - a$ é a amplitude ajustada para a localidade. No refit horário anterior a 2024, Q64 corresponde a passos entre 16,24 e 18,04 W/m² nas dez localidades. Sob a hipótese idealizada de erro de arredondamento uniforme em cada intervalo, o RMS seria $\Delta/\sqrt{12}$, entre 4,69 e 5,21 W/m² [8]. Essa aproximação descreve a entrada, não um erro empírico medido nem um limite para a saída da rede; a propagação depende da função aprendida.

Figura 4 — Quantização uniforme e saturação das entradas



Fonte: elaboração própria. Escada com oito níveis exclusivamente para legibilidade. As execuções avaliadas usam 64, 128 e 256 níveis; a linha tracejada representa o controle sem clipping.

3.6 Treinamento, seleção e refit

Para cada modelo, tarefa, condição de entrada e semente, ajusta-se uma rede global pelo MSE normalizado. As épocas são escolhidas pela perda de validação; a condição de entrada, pelo macro-MAE da previsão combinada na validação, em W/m², no horizonte completo. Em empate, priorizam-se controle, 64, 128 e 256 níveis. A condição permanece fixa no teste e nos horizontes menores. A análise distingue entradas contínuas comuns das configurações selecionadas para cada rede. A Figura 3 e as Tabelas 16 e 17 detalham o protocolo e as implementações.

No refit, a rede é reinicializada na mesma semente e treinada com todo o período anterior ao teste, incluindo a validação, pelas épocas selecionadas. O teste não orienta escolhas. Épocas e entrada compartilham a validação; o protocolo não é uma validação aninhada.

Tabela 5 — Parâmetros efetivos de treinamento por tarefa

Tarefa	Épocas máximas	Paciência	Lote	Sementes	Dispositivo
Horária	30	5	128	42	GPU
Diária	30	5	128	11 23 42 67 89	GPU
Mensal um passo	300	30	32	11 23 42 67 89	CPU
Mensal seis passos	300	30	32	11 23 42 67 89	CPU

Fonte: elaboração própria com dados e registros de execução do projeto (Apêndice C). Adam, taxa de aprendizagem 0,001 e weight decay 0,00001. Configurações conferidas nos contratos das execuções; não representam igualdade de custo computacional entre arquiteturas.

Nas tarefas diária e mensais, combinam-se por média aritmética as previsões das cinco sementes da Tabela 5, após reconversão para W/m² e antes do pós-processamento. No horário utiliza-se a semente 42. Avalia-se o erro da previsão combinada, que difere da média dos erros individuais.

O pós-processamento aplica piso zero a todas as previsões. No horário, anula também os valores com elevação solar não positiva no centro do intervalo, calculada com pvlib [10]. Não há teto comum. A média entre sementes precede o piso, pois inverter essa ordem pode alterar os resultados.

3.7 Análise dos dados e métricas

As métricas são calculadas após a inversão da escala e o pós-processamento. Seja $e_i = y_i - \hat{y}_i$, com referência y_i, previsão $\hat{y}_i$ e n pares de origem e passo em uma localidade. As Equações 3 a 6 definem o erro absoluto médio (MAE), o erro quadrático médio (MSE), sua raiz quadrada (RMSE), o RMSE normalizado (nRMSE) e o coeficiente de determinação (R^2). O MAE expressa a magnitude média do erro em W/m² e constitui o critério principal; MSE e RMSE dão maior influência a desvios grandes [11,12].

$$MAE = \frac{\sum_{i=1}^{n} |e_i|}{n} \quad (3)$$

$$MSE = \frac{\sum_{i=1}^{n} e_i^2}{n} \qquad RMSE = \sqrt{\frac{\sum_{i=1}^{n} e_i^2}{n}} \quad (4)$$

$$nRMSE = \frac{RMSE}{\bar{y}} \qquad nRMSE\ em\ \% = 100 \times nRMSE \quad (5)$$

$$R^2 = 1 - \frac{\sum_{i=1}^{n} e_i^2}{\sum_{i=1}^{n} (y_i - \bar{y})^2} \quad (6)$$

O nRMSE divide o RMSE pela média da referência; os CSVs registram a razão, multiplicada por cem nas tabelas percentuais. O R^2 compara o erro quadrático com a variação da referência em torno de sua média. Pode ser negativo e fica indefinido quando o denominador é numericamente nulo. Valores indefinidos não são substituídos por zero.

Para uma métrica M, a Equação 7 calcula a média macro entre L localidades com valores finitos, atribuindo o mesmo peso a cada uma. Todas as dez contribuem aos resultados cumulativos principais. Como a raiz quadrada é não linear, o macro-RMSE difere, em geral, da raiz do macro-MSE.

$$M_{macro} = \frac{\sum_{l=1}^{L} M_l}{L} \quad (7)$$

A avaliação cumulativa reúne os passos de um até H de todas as origens válidas, preservando previsões de origens diferentes para um mesmo alvo. Janelas sobrepostas determinam o peso temporal e impedem tratar as previsões como independentes.

No horário, as emissões à meia-noite fazem os passos exatos de 24, 48 e 72 horas coincidirem com a noite. As métricas cumulativas incluem dia e noite: referência e previsão nulas reduzem o MAE frente ao recorte diurno; o nRMSE depende também da média da referência e não necessariamente diminui. Comparações entre estudos exigem o mesmo recorte horário [12].

4 DESENVOLVIMENTO

4.1 Fundamentos físicos da GHI

A irradiância global horizontal (GHI) é a potência da radiação solar incidente por unidade de área sobre uma superfície horizontal, expressa em W/m². Quando o Sol está acima do horizonte, pode ser escrita como GHI = DHI + DNI cos(θz), em que DHI é a componente difusa horizontal, DNI é a componente direta normal e θz é o ângulo zenital solar. A irradiância é uma densidade de potência, enquanto a irradiação corresponde à energia recebida ao longo de um intervalo. Por isso, a média diária ou mensal da GHI conserva a unidade W/m² [6].

A evolução da GHI combina regularidades geométricas e variações atmosféricas. O movimento aparente do Sol estabelece ciclos diurnos e sazonais, enquanto nuvens, aerossóis e outras condições da atmosfera modificam a radiação que alcança a superfície. A agregação temporal atenua parte das oscilações rápidas, mas pode preservar a sazonalidade e a persistência meteorológica. Por isso, sequências horárias, médias diárias e médias mensais constituem problemas de previsão distintos, cujo desempenho depende da resolução do alvo, do horizonte e das informações disponíveis na emissão [1].

A geometria solar fundamenta o pós-processamento horário descrito na Seção 3.6: previsões noturnas são anuladas com apoio da biblioteca pvlib [10]. Essa restrição utiliza a posição do Sol e deve ser distinguida da capacidade da rede de antecipar variações diurnas associadas à atmosfera.

4.2 LSTM e memória temporal

Redes recorrentes representam uma sequência por estados internos atualizados a cada observação. Em recorrências convencionais, a propagação do sinal de erro pode dificultar o aprendizado de relações entre valores muito distantes no tempo. A arquitetura Long Short-Term Memory (LSTM) enfrenta esse problema por meio de uma estrutura de memória com mecanismos de controle do fluxo de informação [2]. Na previsão temporal, essas relações são aprendidas a partir dos dados, sem especificar uma equação para cada dependência.

A memória de uma LSTM é uma representação aprendida da sequência. Portas multiplicativas controlam sua atualização e a informação transmitida ao estado de saída [2]. A capacidade de recuperar padrões distantes depende da janela de entrada, dos dados e do treinamento.

Neste estudo, a LSTM codifica uma sequência univariada de GHI. Seu último estado oculto é concatenado ao embedding da localidade, e uma camada linear produz diretamente o vetor futuro. Dessa forma, as previsões anteriores não são realimentadas para obter os passos seguintes. A saída permanece contínua mesmo quando o histórico de entrada é quantizado.

O compartilhamento de parâmetros permite aprender regularidades comuns às localidades, enquanto a identificação de cada série representa diferenças locais. O desempenho dessa modelagem global depende também da heterogeneidade do conjunto observado [5]. A LSTM constitui, assim, a referência recorrente para a comparação com as duas implementações de atenção.

4.3 Transformer e atenção

O Transformer modela relações entre posições de uma sequência por mecanismos de atenção, dispensando a recorrência como operação central. Na atenção por produto escalar, consultas, chaves e valores são projeções aprendidas das representações de entrada. A comparação entre consultas e

chaves gera escores que, após normalização, determinam o peso dos valores combinados em cada saída. A formulação escalada é $\text{Attention}(Q,K,V) = \text{softmax}(QK^T/\sqrt{d_k})V$, em que o fator associado à dimensão das chaves controla a escala dos escores [3].

A atenção com múltiplas cabeças combina diferentes projeções para representar relações entre posições. Como a atenção não estabelece, por si só, a ordem temporal, o Transformer incorpora representações posicionais [3]. Seu processamento paralelo difere da recorrência sequencial; o custo e a precisão dependem do comprimento das sequências e da configuração implementada.

O Transformer do projeto utiliza uma estrutura de codificador e decodificador, ou encoder-decoder. As entradas de GHI recebem projeções lineares, posições senoidais e informação estática da localidade. O encoder transforma o histórico em uma memória consultada pelo decoder, que recebe a parte final do contexto observado e posições futuras preenchidas com zeros. Esses zeros são marcadores de entrada. A máscara causal e a ausência dos alvos no decoder preservam a separação entre informações disponíveis e valores a prever, no treinamento e na inferência.

Uma camada de saída converte as representações futuras em previsões contínuas de GHI. Essa adaptação do Transformer à regressão temporal utiliza os mecanismos de atenção da arquitetura original [3], sem recorrer a um modelo de linguagem previamente treinado. A comparação com a LSTM considera o mesmo histórico sob as tarefas, transformações e regras de treinamento adotadas.

4.4 Informer e atenção esparsa

O Informer foi desenvolvido para prever sequências temporais longas, nas quais a atenção completa pode exigir recursos elevados ao relacionar todos os pares de posições. Seu mecanismo ProbSparse concentra o cálculo detalhado em consultas selecionadas por uma medida estimada por amostragem. O trabalho original associa essa estratégia à redução da complexidade da atenção de $O(L^2)$ para $O(L \log L)$, sendo L o comprimento da sequência. Essa propriedade assintótica motiva o uso em séries extensas, mas não constitui uma medição de velocidade neste experimento [4].

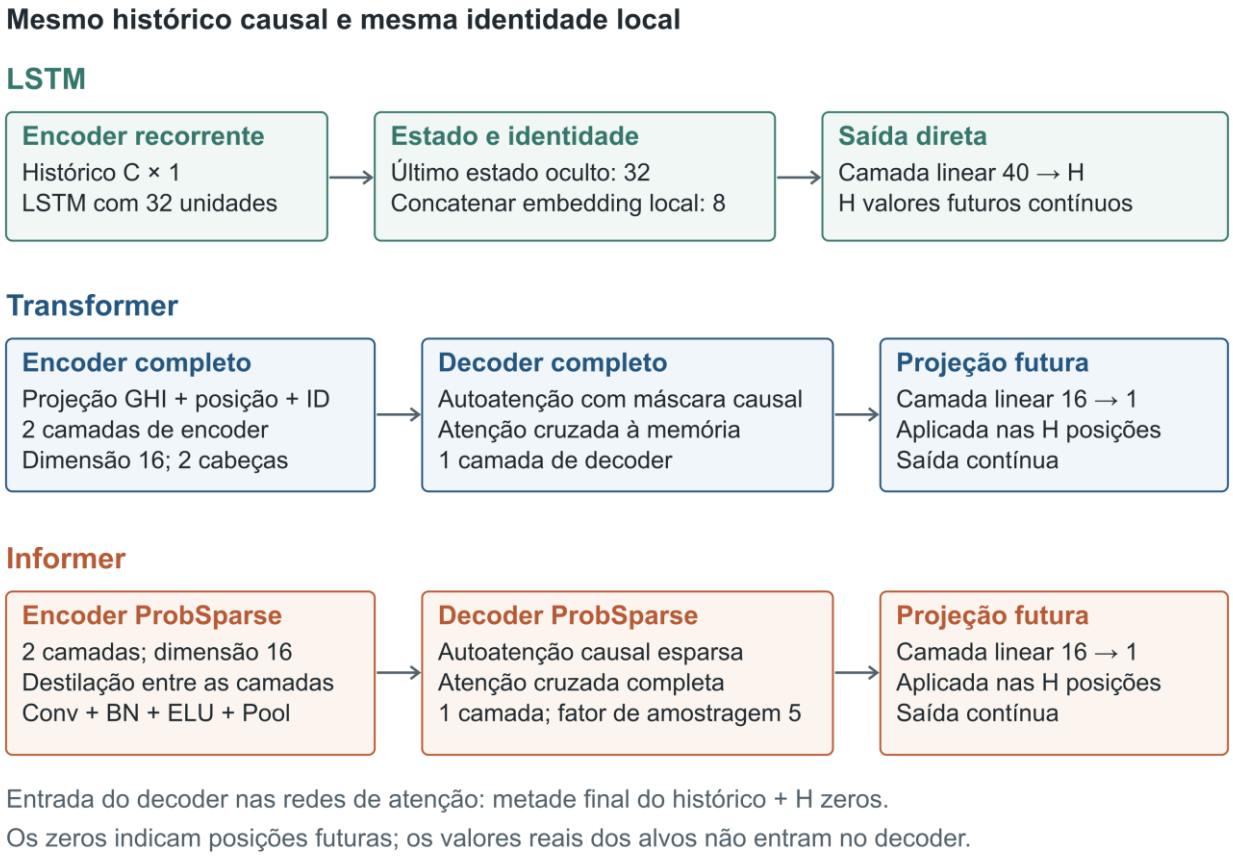
Outros dois componentes do Informer original são a destilação entre camadas do encoder e o decoder que produz o horizonte em uma passagem. A destilação reduz a extensão das representações por convolução, transformação não linear e redução temporal, enquanto o decoder dispensa a realimentação sequencial das previsões anteriores [4].

O Informer do projeto utiliza a mesma estrutura de entrada do Transformer e incorpora ProbSparse na autoatenção do encoder e na autoatenção causal do decoder. Entre as camadas do encoder, aplica a destilação temporal. A atenção cruzada, pela qual o decoder consulta a memória do encoder, permanece completa. Mantêm-se também as projeções da GHI, a representação da localidade e os zeros nas posições futuras.

O número de consultas selecionadas é limitado pelo comprimento da sequência; em contextos curtos, todas podem ser utilizadas. Portanto, o uso de atenção esparsa não assegura economia computacional nas tarefas mensais. As diferenças de erro entre Informer e Transformer refletem o conjunto das implementações, sem isolar o efeito da amostragem da atenção. A avaliação deste TCC se concentra na precisão preditiva; o custo computacional não foi medido.

A Figura 5 sintetiza as implementações e identifica as operações compartilhadas e específicas de cada rede.

Figura 5 — Estruturas implementadas dos três modelos



Fonte: elaboração própria. Esquemas próprios baseados no código do projeto. Os zeros do decoder marcam posições futuras e não fornecem os valores do alvo.

4.5 Trabalhos relacionados e posicionamento

A comparação entre estudos de previsão solar depende da variável prevista, da resolução temporal, do horizonte, das informações disponíveis na emissão e dos períodos e métricas de avaliação [1,12]. Esses elementos orientam a seleção dos trabalhos relacionados e delimitam o confronto com os resultados deste TCC.

Guariso, Nunnari e Sangiorgio [13] estudaram a previsão de irradiância global a partir de seus próprios valores anteriores, incluindo redes LSTM. Utilizaram históricos de 24 horas e horizontes de uma a doze horas e avaliaram a aplicação das redes em outras estações sem novo treinamento. O trabalho oferece um antecedente para o uso do histórico de irradiância como entrada dinâmica. Neste TCC, as tarefas e localidades são diferentes, os parâmetros são compartilhados entre os locais de ajuste e não se avalia a transferência para localidades inéditas.

A escolha de LSTM, Transformer e Informer reúne memória recorrente, atenção completa e atenção esparsa [2,3,4]. Zeng et al. [14] compararam modelos baseados em Transformer com soluções lineares em conjuntos gerais de séries temporais e mostraram que a maior complexidade arquitetural não assegurou vantagem nesses testes. Esse resultado motiva a avaliação empírica de cada implementação, mas não determina a classificação das redes na previsão solar.

Na previsão solar, Chen e Zhou [15] adaptaram o Informer combinando um mecanismo de previsão em janelas deslizantes com explicações pelo método LIME. O estudo utilizou dados meteorológicos de Beijing, nos períodos de verão e inverno, com intervalos de 10, 30 e 60 minutos. Essa aplicação fornece um antecedente solar para a arquitetura, sob entradas e processamento diferentes dos usados neste TCC. Seus resultados não constituem uma comparação direta com as redes aqui treinadas apenas com histórico de GHI e identidade da localidade.

Cabral, Fraidenraich e Capretz [16] investigaram a previsão mensal de longo prazo de GHI da NSRDB com GPT-Neo. O uso do histórico solar aproxima esse trabalho do presente estudo. Entretanto, as diferenças de localidades, horizontes, processamento e modelos exigem que seus resultados sejam discutidos separadamente dos experimentos deste TCC.

A transformação das entradas também exige distinguir a teoria de quantização [8] da inferência com pesos e ativações em aritmética inteira [9]. Neste TCC, apenas o histórico de GHI é discretizado e reconstruído em float32; pesos, alvos e saídas permanecem contínuos. Avalia-se a resposta preditiva à representação da entrada, sem medir ganhos de memória ou velocidade.

Este TCC compara as implementações de Transformer, Informer e LSTM na previsão de GHI em diferentes tarefas, horizontes e localidades. As quatro condições de entrada e as diferentes durações do histórico permitem examinar a sensibilidade dessa comparação ao processamento e aos dados disponíveis para ajuste. As escolhas de configuração permanecem fixadas pela validação, e os resultados descrevem as execuções específicas das três redes.

5 RESULTADOS

A comparação entre Transformer, Informer e LSTM utiliza o horizonte cumulativo completo de cada tarefa e a condição de entrada selecionada na validação. Os controles contínuos também permitem comparar as três redes sob uma condição de entrada comum. O Apêndice A detalha os horizontes menores, e o Apêndice B reúne os MAEs das quatro condições nos três regimes temporais. Classificações e gráficos são calculados com a precisão integral dos arquivos; os valores são arredondados apenas na apresentação.

A análise começa pelo teste de 2024 e examina o desempenho agregado, as diferenças entre localidades e o comportamento por horizonte. Em seguida, a quantização e os históricos pareados são examinados como análises complementares, e os registros de treinamento contextualizam as diferenças observadas. Todos os resultados desta seção pertencem a Transformer, Informer e LSTM.

5.1 Desempenho no teste de 2024

Tabela 6 — Resultados cumulativos completos no regime atual

Tarefa	Modelo	Entrada	MAE W/m²	RMSE W/m²	nRMSE %	R²
Horária 72 h	Transformer	Controle	53,21	103,72	51,64	0,8607
Horária 72 h	Informer	Controle	137,68	245,55	118,52	0,2899
Horária 72 h	LSTM	64	53,52	104,72	52,23	0,8571
Diária 30 d	Transformer	256	43,89	55,12	26,54	0,5330
Diária 30 d	Informer	64	45,46	56,75	27,32	0,5098
Diária 30 d	LSTM	Controle	44,18	55,72	26,80	0,5281
Mensal 1 m	Transformer	128	13,15	16,53	8,22	0,8969
Mensal 1 m	Informer	128	12,73	16,11	7,98	0,9070
Mensal 1 m	LSTM	128	14,29	17,46	8,46	0,8855
Mensal 6 m	Transformer	64	14,40	17,62	7,62	0,8562
Mensal 6 m	Informer	128	13,67	17,11	7,41	0,8672
Mensal 6 m	LSTM	128	14,76	18,12	7,70	0,8380

Fonte: elaboração própria com dados e registros de execução do projeto (Apêndice C). Métricas agregadas por média dos valores locais, com pesos iguais. Entrada é o nível escolhido na validação; Controle indica ausência de quantização.

A Tabela 6 reúne as configurações selecionadas na validação de 2023 e avaliadas no teste de 2024. Nos controles contínuos, o Transformer liderou os horizontes completos horário e diário, com macro-MAEs de 53,21 e 43,88 W/m²; o Informer liderou um e seis meses, com 12,85 e 13,88 W/m². Esses controles, detalhados no Apêndice B, oferecem uma comparação sob condição de entrada comum. Tanto os controles quanto as configurações selecionadas utilizam a semente 42 na tarefa horária e a média das previsões de cinco sementes nas demais tarefas, conforme a Seção 3.6.

Nas configurações selecionadas da Tabela 6, o Transformer apresentou os menores macro-MAEs nos horizontes completos horário e diário, de 53,21 e 43,89 W/m², com vantagens de 0,32 e 0,30 W/m² sobre a LSTM. A proximidade entre essas redes torna relevante examinar os recortes por

horizonte e localidade. O Informer obteve MAE horário de 137,68 W/m². Esse resultado caracteriza a execução avaliada; uma única semente é insuficiente para determinar a causa do erro elevado.

Nas tarefas mensais, o Informer com 128 níveis apresentou os menores macro-MAEs: 12,73 W/m² em um passo e 13,67 W/m² em seis passos. Em cada uma das quatro tarefas, a ordem dos três modelos no horizonte completo foi a mesma nos controles contínuos e nas configurações selecionadas. Assim, a mudança de liderança entre as tarefas horária e mensal também aparece quando as redes recebem entradas contínuas. Essa concordância se refere aos horizontes completos e não implica liderança em todos os locais ou passos. A Tabela 6 compara as redes com suas configurações escolhidas na validação, sem isolar o efeito da arquitetura.

5.2 Heterogeneidade entre localidades

Figura 6 — Desempenho por localidade nas quatro tarefas

MAE por localidade no teste de 2024

Horizonte cumulativo completo e condição de entrada escolhida na validação

a) Horária até 72 horas

	Transformer Controle	Informer Controle	LSTM Q64
BYD Camaçari	55,6	151,7	**53,3**
Tesla Nevada	**42,2**	136,8	43,3
Tesla Texas	**59,9**	140,7	60,2
Hyundai Georgia	62,5	131,7	**62,5**
Rivian Normal	62,2	122,0	**61,8**
Tesla Fremont	**38,4**	145,2	38,9
Lucid Casa Grande	**34,9**	156,0	36,3
GM Factory Zero	**62,7**	112,8	63,9
Ford Rouge EV	**62,3**	110,6	63,1
BMW S. L. Potosí	**51,5**	169,2	51,9

Escala própria: 34,9 W/m² – 169,2 W/m²

b) Diária até 30 dias

	Transformer Q256	Informer Q64	LSTM Controle
BYD Camaçari	**42,6**	44,6	43,8
Tesla Nevada	**35,4**	37,7	36,3
Tesla Texas	50,7	51,6	**50,5**
Hyundai Georgia	**53,4**	54,6	53,5
Rivian Normal	53,9	56,5	**53,0**
Tesla Fremont	**29,5**	31,6	33,4
Lucid Casa Grande	**26,4**	29,5	27,6
GM Factory Zero	54,0	54,6	**53,4**
Ford Rouge EV	**52,3**	53,3	52,3
BMW S. L. Potosí	40,9	40,7	**38,0**

Escala própria: 26,4 W/m² – 56,5 W/m²

c) Mensal um passo

	Transformer Q128	Informer Q128	LSTM Q128
BYD Camaçari	15,2	**14,3**	15,9
Tesla Nevada	**5,9**	8,3	10,8
Tesla Texas	13,9	**11,1**	16,1
Hyundai Georgia	14,0	12,9	**12,1**
Rivian Normal	16,1	**13,6**	17,0
Tesla Fremont	**7,0**	9,0	9,8
Lucid Casa Grande	8,8	**8,8**	13,7
GM Factory Zero	15,6	15,0	**12,3**
Ford Rouge EV	15,5	15,3	**12,0**
BMW S. L. Potosí	19,5	**19,1**	23,2

Escala própria: 5,9 W/m² – 23,2 W/m²

d) Mensal seis passos Exploratório

	Transformer Q64	Informer Q128	LSTM Q128
BYD Camaçari	14,8	**12,6**	14,8
Tesla Nevada	**8,1**	8,4	11,9
Tesla Texas	16,6	**14,2**	15,1
Hyundai Georgia	15,2	15,4	**14,6**
Rivian Normal	**14,5**	14,7	17,6
Tesla Fremont	8,7	**8,1**	11,0
Lucid Casa Grande	12,5	**12,2**	14,4
GM Factory Zero	16,3	15,3	**11,1**
Ford Rouge EV	13,8	13,6	**10,8**
BMW S. L. Potosí	23,4	**22,1**	26,4

Escala própria: 8,1 W/m² – 26,4 W/m²

Contorno e negrito indicam o menor MAE da localidade. A comparação é descritiva.

Fonte: elaboração própria. Métricas locais de teste com seleção fixa pela validação. Escala de cor própria por painel. Contorno e negrito indicam o menor MAE local com a precisão integral dos dados; valores arredondados podem parecer empatados. A comparação é descritiva e não indica significância estatística.

A média macro atribui o mesmo peso às dez localidades, mas pode ocultar mudanças de liderança. A Figura 6 apresenta os MAEs de cada local com a mesma condição de entrada utilizada na classificação agregada. Cada painel corresponde a uma tarefa e ao seu horizonte cumulativo completo.

O Transformer apresenta o menor MAE em sete localidades na tarefa horária e seis na diária. A LSTM lidera nas três e quatro localidades restantes, respectivamente. Nas tarefas mensais de um e seis passos, o Informer lidera em cinco localidades, a LSTM em três e o Transformer em duas. Logo, o primeiro lugar na média macro não equivale a liderança em todos os locais.

Nos dois pontos de Detroit, GM Factory Zero e Ford Rouge EV Center, a LSTM apresentou o menor MAE nas duas tarefas mensais. Esse comportamento reforça que a melhor configuração na média macro pode perder para outra rede em uma localidade específica. Os dados revelam a heterogeneidade, mas não identificam sua causa climática.

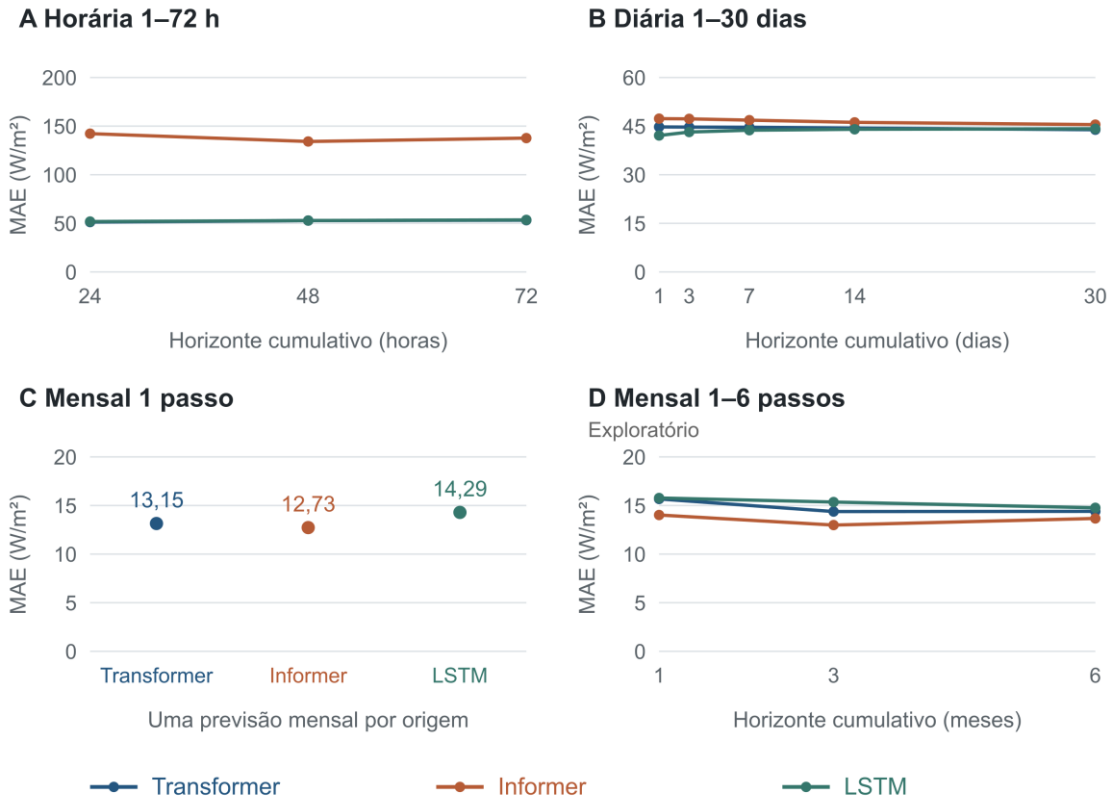
5.3 Comportamento nos horizontes cumulativos

A Figura 7 mostra como o erro cumulativo evolui com o horizonte, mantendo a condição selecionada na validação. No Transformer horário, o MAE passou de 51,29 para 52,83 e 53,21 W/m² em 24, 48 e 72 horas. Na LSTM com 64 níveis, os valores foram 51,84, 52,88 e 53,52 W/m². O crescimento foi limitado nesses recortes, e a pequena vantagem agregada do Transformer permaneceu nos três horizontes.

No diário, a classificação depende do horizonte avaliado. A LSTM apresentou menor MAE nos recortes de 1, 3, 7 e 14 dias, enquanto o Transformer liderou no horizonte completo de 30 dias. O MAE cumulativo da LSTM passou de 42,11 W/m² em um dia para 44,18 W/m² em 30 dias. No Transformer, passou de 44,75 para 43,89 W/m². A redução de uma média cumulativa não significa que prever individualmente o trigésimo dia seja mais fácil, pois os recortes combinam passos distintos.

Na tarefa mensal de seis passos, o Informer com 128 níveis apresentou MAEs cumulativos de 14,02, 12,99 e 13,67 W/m² em um, três e seis meses. O primeiro valor corresponde ao passo inicial da rede treinada para seis saídas e não ao resultado da rede mensal de um passo. O teste de 2024 tem sete origens por localidade, totalizando 420 pares de origem e passo nas dez localidades. Como as janelas compartilham alvos, esses pares não são observações independentes. A avaliação permanece exploratória.

Figura 7 — Perfis cumulativos de erro nos horizontes de cada tarefa



Fonte: elaboração própria. Macro-MAE cumulativo, com pesos iguais entre localidades. A condição de entrada permanece fixa pela escolha no horizonte completo da validação. O painel mensal de seis passos é exploratório.

5.4 Quantização como análise de pré-processamento

Tabela 7 — Nível escolhido e comparação com o controle no teste de 2024

Tarefa	Modelo	Escolha	MAE val	MAE controle teste	MAE escolha teste	Δ teste %
Horária 72 h	Transformer	Controle	54,43	53,21	53,21	0,00
Horária 72 h	Informer	Controle	131,09	137,68	137,68	0,00
Horária 72 h	LSTM	64	53,49	54,09	53,52	-1,05
Diária 30 d	Transformer	256	44,47	43,88	43,89	0,01
Diária 30 d	Informer	64	45,23	45,47	45,46	-0,02
Diária 30 d	LSTM	Controle	45,49	44,18	44,18	0,00
Mensal 1 m	Transformer	128	14,98	13,12	13,15	0,21
Mensal 1 m	Informer	128	14,49	12,85	12,73	-0,95
Mensal 1 m	LSTM	128	15,59	14,27	14,29	0,12
Mensal 6 m	Transformer	64	16,61	14,43	14,40	-0,23

Tarefa	Modelo	Escolha	MAE val	MAE controle teste	MAE escolha teste	Δ teste %
Mensal 6 m	Informer	128	17,10	13,88	13,67	-1,53
Mensal 6 m	LSTM	128	16,26	14,76	14,76	0,04

Fonte: elaboração própria com dados e registros de execução do projeto (Apêndice C). Todos os MAEs em W/m². Δ = 100 × (MAE escolha / MAE controle − 1). A condição é selecionada na validação; a última coluna descreve seu desempenho posterior no teste.

Esta análise examina a quantização como opção de pré-processamento das entradas e verifica como a condição selecionada se comporta no teste. A Figura 8 apresenta a variação de MAE dos três níveis em relação ao controle do mesmo modelo e tarefa. Cada variante tem seu próprio ajuste e número de épocas escolhido na validação; as quantizadas também aplicam clipping. A Tabela 7 destaca a condição selecionada antes do teste, inclusive quando é o controle.

A condição de entrada selecionada na validação reduziu o MAE de teste em cinco das 12 combinações de modelo e tarefa, elevou-o em quatro e manteve o controle contínuo em três. A LSTM horária com 64 níveis apresentou redução de 1,05% em relação ao seu controle. No Informer com 128 níveis, as reduções foram de 0,95% na tarefa mensal de um passo e 1,53% na de seis passos. Já o Transformer diário com 256 níveis apresentou aumento de 0,01%. Assim, uma condição favorável na validação pode perder sua vantagem no teste.

A condição escolhida na validação é preservada mesmo quando outro nível obtém menor erro no teste. A LSTM horária selecionou 64 níveis, embora 256 níveis tenham apresentado menor MAE posterior. No Informer mensal de um passo, os 128 níveis selecionados resultaram em 12,73 W/m², enquanto 256 níveis alcançaram 12,32 W/m². Esses valores ajudam a caracterizar a sensibilidade, mas utilizá-los para refazer a escolha transformaria o teste em outra etapa de seleção. As diferenças permanecem descritivas, sem demonstração de significância estatística.

Os diagnósticos do teste de 2024 registram clipping em 14 de 1.219.680 entradas horárias (0,0011%) e 328 de 1.230.050 diárias (0,0267%); nas duas tarefas mensais, não há saturação no teste. Essas contagens se referem a valores escalares nas janelas de entrada, que podem se sobrepor, e não a observações independentes ou erros de previsão. Na validação de 2023, porém, há 24 de 1.440 entradas saturadas na tarefa mensal de um passo (1,67%) e nove de 840 na de seis passos (1,07%). A baixa incidência no teste caracteriza essa etapa, mas não exclui influência anterior na escolha de épocas e níveis nem mede a magnitude de seu efeito nas previsões.

Figura 8 — Sensibilidade do MAE à resolução de amplitude no regime atual

Variação do MAE de teste em relação à entrada contínua

Verde: menor erro · laranja: maior erro · ★ escolha na validação

Modelo	Validação	64 níveis	128 níveis	256 níveis
Horária 1–72 h				
Transformer	Controle ★	+0,00%	+0,02%	+0,02%
Informer	Controle ★	+0,14%	+0,12%	-0,02%
LSTM	64 níveis	**★ -1,05%**	+0,37%	-1,69%
Diária 1–30 dias				
Transformer	256 níveis	-0,01%	-0,00%	**★ +0,01%**
Informer	64 níveis	**★ -0,02%**	-0,01%	+0,03%
LSTM	Controle ★	+0,05%	+0,99%	+0,52%
Mensal 1 passo				
Transformer	128 níveis	-0,59%	**★ +0,21%**	-0,12%
Informer	128 níveis	-2,34%	**★ -0,95%**	-4,13%
LSTM	128 níveis	-0,01%	**★ +0,12%**	+0,01%
Mensal 1–6 passos · exploratório				
Transformer	64 níveis	**★ -0,23%**	+0,39%	+0,02%
Informer	128 níveis	-1,97%	**★ -1,53%**	-1,48%
LSTM	128 níveis	-0,04%	**★ +0,04%**	+0,13%

Δ = 100 × (MAE quantizado / MAE controle − 1). As células descrevem o teste.
Intensidade de cor saturada em |Δ| ≥ 10%; valores exatos indicados em cada célula.

Fonte: elaboração própria. Variações do macro-MAE calculadas em relação ao controle do mesmo modelo e tarefa. Estrela identifica a condição escolhida na validação; contorno destaca escolhas quantizadas.

5.5 Análise complementar da duração do histórico

Para contextualizar a comparação entre as redes, os históricos longo e curto são confrontados nos mesmos alvos e datas de validação e teste, conforme a Tabela 3. Na tarefa horária, ambos utilizam as 1.368 origens válidas por localidade após a exclusão da janela incompleta descrita na metodologia. O pareamento evita que a mudança do período de avaliação se confunda com a ampliação do histórico.

A Tabela 8 mostra que, nos controles contínuos, o histórico longo apresentou menor MAE em 11 das 12 combinações de modelo e tarefa. No Informer horário, o erro passou de 136,21 para 60,90 W/m², redução de 55,29%. A exceção foi a LSTM horária, cujo MAE aumentou de 53,72 para 61,61

W/m², ou 14,68%. Incorporar anos anteriores esteve, assim, associado à melhora na maioria das configurações, sem garanti-la.

A métrica também pode alterar a ordenação. No histórico longo diário, a LSTM selecionada apresentou MAE de 43,20 W/m², próximo dos 43,21 W/m² do Informer. Pelo RMSE, o Informer obteve menor valor: 54,80 contra 55,22 W/m². Como o RMSE dá maior influência aos desvios grandes, esse exemplo justifica a leitura de medidas complementares ao MAE, mantido como critério principal do protocolo.

Tabela 8 — Comparação pareada dos históricos no controle sem quantização

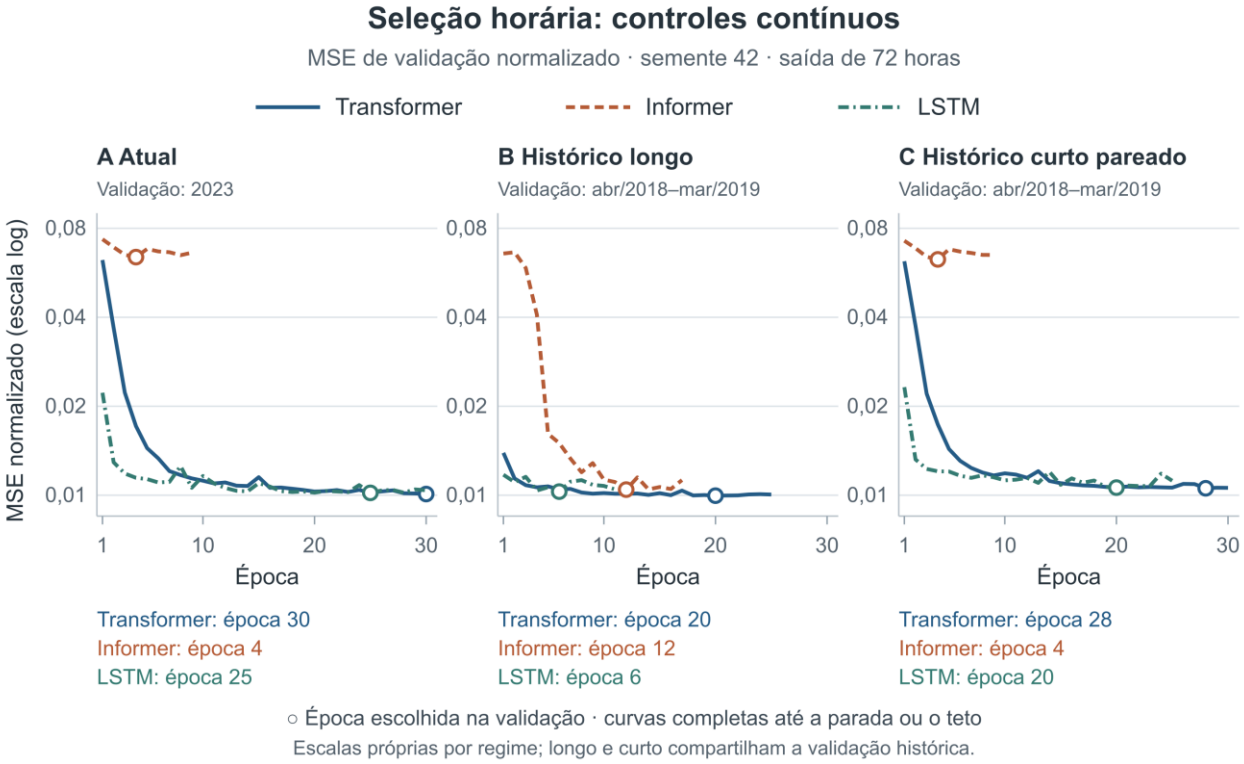
Tarefa	Modelo	MAE curto	MAE longo	Δ longo %
Horária 72 h	Transformer	55,48	52,37	-5,61
Horária 72 h	Informer	136,21	60,90	-55,29
Horária 72 h	LSTM	53,72	61,61	14,68
Diária 30 d	Transformer	44,67	44,48	-0,41
Diária 30 d	Informer	46,02	43,59	-5,28
Diária 30 d	LSTM	44,27	43,28	-2,23
Mensal 1 m	Transformer	16,40	14,08	-14,12
Mensal 1 m	Informer	16,22	13,88	-14,40
Mensal 1 m	LSTM	15,45	14,66	-5,09
Mensal 6 m	Transformer	17,20	14,91	-13,28
Mensal 6 m	Informer	16,22	14,72	-9,23
Mensal 6 m	LSTM	15,39	15,05	-2,20

Fonte: elaboração própria com dados e registros de execução do projeto (Apêndice C). MAE em W/m². Mesmo teste histórico. Δ negativo indica menor MAE com o histórico longo.

5.6 Diagnóstico dos registros de treinamento

A Figura 9 apresenta as trajetórias de seleção horária dos controles contínuos. Elas complementam a comparação da Tabela 8, sem alterar as condições selecionadas na validação utilizadas nas tabelas principais. Nos controles do regime atual, as épocas escolhidas foram 30 para Transformer, quatro para Informer e 25 para LSTM.

Figura 9 — Trajetórias de validação dos controles contínuos na tarefa horária



Fonte: elaboração própria com os registros de seleção dos três modelos, semente 42. MSE de validação normalizado em eixo vertical logarítmico; círculos indicam as épocas escolhidas. O regime atual avalia 2023; os históricos compartilham a validação, mas usam escalas ajustadas em períodos distintos. As curvas incluem as épocas registradas até a parada antecipada ou o teto de 30 épocas e não isolam o efeito da duração do histórico.

Nos controles horários dos regimes atual e histórico curto, o Informer apresentou uma trajetória de validação distinta das demais redes. Com o histórico longo, sua perda diminuiu ao longo das épocas registradas. Essas curvas caracterizam a otimização nas configurações executadas, mas não isolam a causa do erro de teste nem demonstram convergência. A interpretação também deve considerar a semente única e as escalas próprias de cada regime: longo e curto compartilham os alvos de validação, enquanto o regime atual avalia outro período.

A época escolhida coincidiu com o teto de 30 em quatro das quatro condições de entrada do Transformer horário no regime atual. Na tarefa diária atual, isso ocorreu em oito de 20 combinações de condição e semente do Transformer e em cinco de 20 da LSTM; na tarefa diária do histórico curto pareado, ocorreu em onze de 20 combinações da LSTM. Esses casos indicam que a busca por épocas terminou na fronteira do orçamento estabelecido. Não demonstram, por si só, que as redes ficaram subtreinadas ou que ampliar o orçamento reduziria o erro de teste; essa hipótese exigiria outra avaliação.

5.7 Discussão integrada e limitações

A comparação entre os modelos mostrou que a ordenação varia entre tarefas, localidades e horizontes. Nos horizontes completos de 2024, a classificação dos três modelos foi a mesma sob controle contínuo e sob as configurações selecionadas na validação. O resultado mensal favorável do Informer não se estendeu à tarefa horária, e as pequenas diferenças agregadas entre Transformer e LSTM coexistiram com mudanças de liderança local. Esses resultados não sustentam uma preferência

geral por arquitetura. A comparação utiliza dados e regras de avaliação comuns, mas as tarefas diferem em resolução, contexto e horizonte, e as redes não têm capacidade ou custo computacional equalizados.

Como análise de pré-processamento, a quantização não apresentou benefício uniforme, e a condição escolhida na validação nem sempre preservou a vantagem sobre o controle no teste. A análise dos demais níveis caracteriza essa sensibilidade sem refazer a seleção. Uma possível regularização por redução de precisão permanece como hipótese: o desenho combina arredondamento com clipping e não identifica um mecanismo isolado. Um controle com apenas clipping permitiria separar melhor esses efeitos.

Na comparação histórica pareada, ampliar o conjunto de ajuste esteve associado a menor erro na maioria das configurações, com exceção da LSTM horária. A inclusão de anos anteriores modifica simultaneamente o número de janelas, a composição dos anos e os extremos da normalização. Por isso, o resultado descreve o efeito conjunto dessa ampliação, sem isolar a quantidade de observações como causa da melhora.

As tarefas mensais dispõem de poucas origens de teste, sobretudo a de seis passos. A sobreposição de alvos gera dependência temporal, e pode haver correlação espacial entre localidades. As médias macro resumem o desempenho, mas não quantificam essas dependências e podem ocultar perdas locais. Novos anos de teste e recortes sazonais permitiriam examinar a estabilidade das diferenças observadas.

A avaliação utiliza um produto modelado da NSRDB e localidades escolhidas intencionalmente. Além disso, o teste de 2024 já havia sido examinado em etapas anteriores do projeto. Embora as execuções aqui comparadas respeitem a separação temporal descrita, essa exposição anterior limita a independência do teste e caracteriza a análise como retrospectiva. O estudo pressupõe o acesso ao histórico e não reproduz a aquisição de dados em tempo real ou a operação de uma instalação fotovoltaica.

A tarefa horária utiliza uma única semente, de modo que sua ordenação pode depender da inicialização e da trajetória de treinamento. Nas demais tarefas, a média de cinco sementes reduz a dependência de uma execução, mas não fornece intervalo de confiança nem previsão probabilística calibrada. As conclusões são descritivas. Os artefatos preservados permitem rastrear os resultados consolidados; sementes fixas, por si só, não garantem repetição bit a bit de novos treinamentos em GPU.

A comparação se restringe às três implementações avaliadas e não estabelece uma classificação geral dos métodos de previsão solar [12]. Como o protocolo não inclui persistência ou climatologia, também não quantifica o ganho em relação a essas referências simples. A eficiência computacional exigiria outra avaliação: as entradas discretizadas permanecem em float32 e os pesos não são quantizados, sem implementação ou medição de redução de memória e tempo de execução.

6 CONCLUSÃO

O TCC comparou Transformer, Informer e LSTM na previsão de GHI em quatro tarefas temporais. No teste de 2024, com as configurações selecionadas na validação, o Transformer apresentou os menores MAEs cumulativos completos nas tarefas horária e diária, de 53,21 e 43,89 W/m². O Informer liderou as tarefas mensais de um e seis passos, com 12,73 e 13,67 W/m². A classificação dos três modelos em cada horizonte completo também foi observada nos controles contínuos. Os resultados descrevem as implementações, os dados e as configurações avaliadas.

A resposta à comparação entre os modelos depende da tarefa e do recorte de avaliação. A LSTM liderou os horizontes diários de 1, 3, 7 e 14 dias, enquanto o Transformer apresentou menor MAE no horizonte completo de 30 dias. A análise por localidade também revelou mudanças de liderança em relação à média macro. Portanto, o resultado agregado orienta a escolha entre as configurações avaliadas para cada tarefa, sem estabelecer superioridade geral de uma arquitetura. As diferenças pequenas permanecem descritivas, sem demonstração de significância estatística.

A quantização foi examinada como opção de pré-processamento. A condição quantizada selecionada reduziu o MAE em cinco das doze combinações de modelo e tarefa de 2024 e o elevou em quatro; nas três restantes, selecionou-se o controle contínuo. A resposta variou conforme o modelo e a tarefa, e a escolha de uma entrada quantizada na validação não garantiu vantagem posterior. Manter a escolha original preservou a função do teste. Como as variantes também incluem clipping, os resultados caracterizam a transformação conjunta, sem identificar um benefício exclusivo do arredondamento.

A análise complementar da duração do histórico mostrou redução de MAE nos controles contínuos em onze das doze combinações pareadas. A exceção da LSTM horária indica que incluir anos anteriores não garante melhora. Como essa ampliação modifica a quantidade de janelas, os anos representados e os extremos da normalização, o resultado não isola um mecanismo causal único. As trajetórias de treinamento também variaram entre os históricos e ajudam a contextualizar as execuções, sem explicar isoladamente suas diferenças de erro.

As próximas investigações podem examinar a estabilidade da comparação entre os modelos em novos anos de teste, com mais sementes na tarefa horária e diferentes orçamentos de treinamento, mantendo as escolhas anteriores ao teste. Referências simples, como persistência e climatologia, permitiriam avaliar o ganho das redes em relação a alternativas de menor complexidade. Caso a análise do pré-processamento seja aprofundada, um controle com apenas clipping ajudaria a distinguir seus efeitos dos do arredondamento. A eficiência de implantação requer uma etapa própria de implementação e medição, além da precisão preditiva estudada aqui.

7 REFERÊNCIAS BIBLIOGRÁFICAS

[1] DIAGNE, M.; DAVID, M.; LAURET, P.; BOLAND, J.; SCHMUTZ, N. Review of solar irradiance forecasting methods and a proposition for small-scale insular grids. Renewable and Sustainable Energy Reviews, v. 27, p. 65–76, 2013. DOI: 10.1016/j.rser.2013.06.042.

[2] HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. Neural Computation, v. 9, n. 8, p. 1735–1780, 1997. DOI: 10.1162/neco.1997.9.8.1735.

[3] VASWANI, A. et al. Attention Is All You Need. Advances in Neural Information Processing Systems, v. 30, p. 5998–6008, 2017. Disponível em: https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.

[4] ZHOU, H. et al. Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting. Proceedings of the AAAI Conference on Artificial Intelligence, v. 35, n. 12, p. 11106–11115, 2021. DOI: 10.1609/aaai.v35i12.17325.

[5] MONTERO-MANSO, P.; HYNDMAN, R. J. Principles and algorithms for forecasting groups of time series: Locality and globality. International Journal of Forecasting, v. 37, n. 4, p. 1632–1653, 2021. DOI: 10.1016/j.ijforecast.2021.03.004.

[6] SENGUPTA, M.; XIE, Y.; LOPEZ, A.; HABTE, A.; MACLAURIN, G.; SHELBY, J. The National Solar Radiation Data Base (NSRDB). Renewable and Sustainable Energy Reviews, v. 89, p. 51–60, 2018. DOI: 10.1016/j.rser.2018.03.003.

[7] NATIONAL LABORATORY OF THE ROCKIES. GOES Aggregated: PSM v4 Download API. Documentação técnica. Disponível em: https://developer.nlr.gov/docs/solar/nsrdb/nsrdb-GOES-aggregated-v4-0-0-download/. Acesso em: 31 out. 2026.

[8] GRAY, R. M.; NEUHOFF, D. L. Quantization. IEEE Transactions on Information Theory, v. 44, n. 6, p. 2325–2383, 1998. DOI: 10.1109/18.720541.

[9] JACOB, B. et al. Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference. In: IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018, p. 2704–2713. DOI: 10.1109/CVPR.2018.00286.

[10] ANDERSON, K. S. et al. pvlib python: 2023 project update. Journal of Open Source Software, v. 8, n. 92, 5994, 2023. DOI: 10.21105/joss.05994.

[11] HYNDMAN, R. J.; KOEHLER, A. B. Another look at measures of forecast accuracy. International Journal of Forecasting, v. 22, n. 4, p. 679–688, 2006. DOI: 10.1016/j.ijforecast.2006.03.001.

[12] YANG, D. et al. Verification of deterministic solar forecasts. Solar Energy, v. 210, p. 20–37, 2020. DOI: 10.1016/j.solener.2020.04.019.

[13] GUARISO, G.; NUNNARI, G.; SANGIORGIO, M. Multi-Step Solar Irradiance Forecasting and Domain Adaptation of Deep Neural Networks. Energies, v. 13, n. 15, 3987, 2020. DOI: 10.3390/en13153987.

[14] ZENG, A.; CHEN, M.; ZHANG, L.; XU, Q. Are Transformers Effective for Time Series Forecasting? Proceedings of the AAAI Conference on Artificial Intelligence, v. 37, n. 9, p. 11121–11128, 2023. DOI: 10.1609/aaai.v37i9.26317.

[15] CHEN, W.; ZHOU, G. An interpretable prediction model for global horizontal irradiance based on Improved-Informer. Measurement, v. 258, parte E, 119449, 2026. DOI: 10.1016/j.measurement.2025.119449.

[16] CABRAL, T. W.; FRAIDENRAICH, G.; CAPRETZ, M. A. M. Can large language models predict solar irradiance in the long term? Solar Energy, v. 317, 114964, 2026. DOI: 10.1016/j.solener.2026.114964.

APÊNDICE A — RESULTADOS POR HORIZONTE NO REGIME ATUAL

As tabelas deste apêndice mantêm, em cada modelo e tarefa, a condição escolhida na validação do horizonte completo. MAE e RMSE estão em W/m²; MSE em (W/m²)². Todas as métricas são macro e cumulativas. As tarefas mensais de um e seis passos são redes distintas. As Tabelas 9 a 12 correspondem, respectivamente, às tarefas horária, diária, mensal de um passo e mensal de seis passos.

Tabela 9 — Detalhamento cumulativo da tarefa horária 72 h

Modelo	H	Entrada	MAE	MSE	RMSE	nRMSE %	R²
Transformer	24	Controle	51,29	10.390,25	100,82	50,21	0,8684
Transformer	48	Controle	52,83	10.871,30	103,10	51,34	0,8624
Transformer	72	Controle	53,21	11.010,18	103,72	51,64	0,8607
Informer	24	Controle	142,25	64.862,35	253,56	122,45	0,2428
Informer	48	Controle	134,19	57.954,86	239,53	115,72	0,3231
Informer	72	Controle	137,68	60.924,69	245,55	118,52	0,2899
LSTM	24	64	51,84	10.275,89	100,04	49,99	0,8687
LSTM	48	64	52,88	10.976,41	103,42	51,63	0,8601
LSTM	72	64	53,52	11.242,94	104,72	52,23	0,8571

Fonte: elaboração própria com dados e registros de execução do projeto (Apêndice C). H em horas, dias ou meses conforme a tarefa.

Tabela 10 — Detalhamento cumulativo da tarefa diária 30 d

Modelo	H	Entrada	MAE	MSE	RMSE	nRMSE %	R²
Transformer	1	256	44,75	3.201,77	55,68	26,85	0,5262
Transformer	3	256	44,69	3.203,12	55,69	26,85	0,5244
Transformer	7	256	44,64	3.208,72	55,72	26,85	0,5226
Transformer	14	256	44,38	3.182,90	55,48	26,71	0,5254
Transformer	30	256	43,89	3.139,69	55,12	26,54	0,5330
Informer	1	64	47,31	3.583,26	59,05	28,49	0,4798
Informer	3	64	47,24	3.566,77	58,92	28,41	0,4794
Informer	7	64	46,84	3.493,90	58,27	28,08	0,4871
Informer	14	64	46,16	3.388,51	57,33	27,61	0,4996
Informer	30	64	45,46	3.316,59	56,75	27,32	0,5098

Modelo	H	Entrada	MAE	MSE	RMSE	nRMSE %	R²
LSTM	1	Controle	42,11	2.970,42	53,68	25,89	0,5643
LSTM	3	Controle	43,18	3.087,77	54,76	26,39	0,5446
LSTM	7	Controle	43,73	3.143,79	55,29	26,61	0,5346
LSTM	14	Controle	44,02	3.176,92	55,57	26,73	0,5293
LSTM	30	Controle	44,18	3.191,41	55,72	26,80	0,5281

Fonte: elaboração própria com dados e registros de execução do projeto (Apêndice C). H em horas, dias ou meses conforme a tarefa.

Tabela 11 — Detalhamento cumulativo da tarefa mensal 1 m

Modelo	H	Entrada	MAE	MSE	RMSE	nRMSE %	R²
Transformer	1	128	13,15	304,94	16,53	8,22	0,8969
Informer	1	128	12,73	279,45	16,11	7,98	0,9070
LSTM	1	128	14,29	328,45	17,46	8,46	0,8855

Fonte: elaboração própria com dados e registros de execução do projeto (Apêndice C). H em horas, dias ou meses conforme a tarefa.

Tabela 12 — Detalhamento cumulativo da tarefa mensal 6 m

Modelo	H	Entrada	MAE	MSE	RMSE	nRMSE %	R²
Transformer	1	64	15,67	377,30	18,72	8,57	0,8750
Transformer	3	64	14,38	336,43	17,62	7,49	0,8419
Transformer	6	64	14,40	337,58	17,62	7,62	0,8562
Informer	1	128	14,02	324,42	17,40	8,01	0,8944
Informer	3	128	12,99	291,11	16,40	6,99	0,8625
Informer	6	128	13,67	317,26	17,11	7,41	0,8672
LSTM	1	128	15,77	410,47	19,49	8,74	0,8541
LSTM	3	128	15,35	389,21	18,85	7,89	0,8082
LSTM	6	128	14,76	360,46	18,12	7,70	0,8380

Fonte: elaboração própria com dados e registros de execução do projeto (Apêndice C). H em horas, dias ou meses conforme a tarefa.

APÊNDICE B — COMPARAÇÃO DAS QUATRO CONDIÇÕES DE ENTRADA

Os MAEs a seguir correspondem ao horizonte completo de cada tarefa. O asterisco identifica a condição escolhida na validação, inclusive quando é o controle. A tabela apresenta todas as condições para tornar visível a sensibilidade; o menor erro de teste não altera a escolha registrada. MAE em W/m². As Tabelas 13 a 15 apresentam os regimes atual, histórico longo e histórico curto pareado, respectivamente.

B.1 Atual

Tabela 13 — MAE por condição de entrada no regime atual

Tarefa	Modelo	Controle	64 níveis	128 níveis	256 níveis
Horária 72 h	Transformer	53,2061 *	53,2072	53,2168	53,2171
Horária 72 h	Informer	137,6798 *	137,8672	137,8436	137,6502
Horária 72 h	LSTM	54,0947	53,5241 *	54,2942	53,1808
Diária 30 d	Transformer	43,8807	43,8784	43,8786	43,8869 *
Diária 30 d	Informer	45,4674	45,4603 *	45,4609	45,4803
Diária 30 d	LSTM	44,1842 *	44,2079	44,6199	44,4134
Mensal 1 m	Transformer	13,1196	13,0420	13,1467 *	13,1037
Mensal 1 m	Informer	12,8481	12,5473	12,7266 *	12,3181
Mensal 1 m	LSTM	14,2711	14,2693	14,2883 *	14,2729
Mensal 6 m	Transformer	14,4302	14,3965 *	14,4868	14,4332
Mensal 6 m	Informer	13,8803	13,6067	13,6679 *	13,6751
Mensal 6 m	LSTM	14,7565	14,7505	14,7623 *	14,7763

Fonte: elaboração própria com dados e registros de execução do projeto (Apêndice C). * Condição escolhida pelo macro-MAE de validação no horizonte completo.

O teste deste regime é 2024. As comparações de quantização devem ser feitas dentro da mesma linha, evitando misturar escalas temporais. O controle permanece como escolha válida; quantizar não é uma exigência da seleção.

B.2 Histórico longo

Tabela 14 — MAE por condição de entrada no regime histórico longo

Tarefa	Modelo	Controle	64 níveis	128 níveis	256 níveis
Horária 72 h	Transformer	52,3673	52,3777	52,3996 *	52,4073
Horária 72 h	Informer	60,8980	60,1353	57,1305 *	59,7161
Horária 72 h	LSTM	61,6058	55,2721 *	52,6016	54,4099
Diária 30 d	Transformer	44,4850	44,4986	44,4859 *	44,4873

Tarefa	Modelo	Controle	64 níveis	128 níveis	256 níveis
Diária 30 d	Informer	43,5925	43,5012	43,7886	43,2117 *
Diária 30 d	LSTM	43,2834	43,1961 *	43,5516	43,3009
Mensal 1 m	Transformer	14,0825	14,2894 *	14,0814	14,0756
Mensal 1 m	Informer	13,8831	14,0359	13,8982	14,1303 *
Mensal 1 m	LSTM	14,6593	14,6602 *	14,6667	14,6686
Mensal 6 m	Transformer	14,9112 *	14,9171	14,9232	14,8961
Mensal 6 m	Informer	14,7247	14,7252 *	14,6693	14,7287
Mensal 6 m	LSTM	15,0537	15,0560 *	15,0483	15,0458

Fonte: elaboração própria com dados e registros de execução do projeto (Apêndice C). * Condição escolhida pelo macro-MAE de validação no horizonte completo.

O teste é comum aos dois regimes históricos, de abril de 2019 a dezembro de 2022. Comparações de duração do histórico devem manter a mesma condição de entrada, ou indicar explicitamente quando cada histórico selecionou um nível diferente.

B.3 Histórico curto

Tabela 15 — MAE por condição de entrada no regime histórico curto

Tarefa	Modelo	Controle	64 níveis	128 níveis	256 níveis
Horária 72 h	Transformer	55,4797	55,4867 *	55,5125	55,4898
Horária 72 h	Informer	136,2112	136,1581	136,1523 *	136,2357
Horária 72 h	LSTM	53,7187	53,7857	56,8112 *	55,7366
Diária 30 d	Transformer	44,6667	44,6719	44,6657 *	44,6657
Diária 30 d	Informer	46,0223	46,4971 *	46,0388	46,0253
Diária 30 d	LSTM	44,2693	44,6329	44,3700 *	44,2247
Mensal 1 m	Transformer	16,3974	16,4656	16,4060 *	16,4124
Mensal 1 m	Informer	16,2183 *	16,2646	16,2255	16,2251
Mensal 1 m	LSTM	15,4460 *	15,4773	15,4459	15,4370
Mensal 6 m	Transformer	17,1950	17,2057 *	17,1874	17,1043
Mensal 6 m	Informer	16,2222	16,3077 *	16,2373	16,2368
Mensal 6 m	LSTM	15,3925	15,4064 *	15,3839	15,3895

Fonte: elaboração própria com dados e registros de execução do projeto (Apêndice C). * Condição escolhida pelo macro-MAE de validação no horizonte completo.

O teste é comum aos dois regimes históricos, de abril de 2019 a dezembro de 2022. Comparações de duração do histórico devem manter a mesma condição de entrada, ou indicar explicitamente quando cada histórico selecionou um nível diferente.

APÊNDICE C — CONFIGURAÇÕES DAS IMPLEMENTAÇÕES

Este apêndice resume as configurações das três implementações e o ambiente das execuções. Os resultados foram consolidados de experimentos já realizados, mantendo as escolhas na validação e o pareamento dos históricos.

C.1 Configurações e parâmetros treináveis

Em todas as tarefas há uma entrada de GHI por instante e uma representação aprendida de oito dimensões para cada uma das dez localidades. C indica o comprimento do histórico e H, o horizonte de saída.

Tabela 16 — Configurações das três arquiteturas

Componente	LSTM	Transformer	Informer
Estado ou dimensão interna	32 unidades	16	16
Camadas recorrentes ou de encoder	1 recorrente	2 encoders	2 encoders
Camadas de decoder	Não se aplica	1	1
Cabeças de atenção	Não se aplica	2	2
Dimensão feedforward	Não se aplica	32	32
Dropout	0	0,1	0,1
Contexto observado no decoder	Não se aplica	⌊C/2⌋	⌊C/2⌋
Fator ProbSparse	Não se aplica	Não se aplica	5

Fonte: elaboração própria com base nas configurações das implementações avaliadas. No Informer, ProbSparse atua nas autoatenções; a atenção cruzada permanece completa. O dropout indicado atua nos blocos residuais e feedforward; os pesos da atenção ProbSparse não recebem dropout nesta implementação.

O decoder das redes de atenção recebe 168 valores observados no horário, 182 no diário e seis nas tarefas mensais, seguidos de H zeros. O Informer aplica uma etapa de destilação entre os encoders: convolução de 16 para 16 canais, kernel 3 e padding circular de 1, seguida de BatchNorm, ELU e max-pooling de kernel 3, passo 2 e padding 1. A saída de atenção usa uma projeção linear de 16 para um compartilhada entre os passos. Na LSTM, o estado de 32 dimensões é concatenado ao embedding de oito e projetado de 40 para H.

Tabela 17 — Quantidade de parâmetros treináveis por tarefa

Tarefa	LSTM	Transformer	Informer
Horária	7.512	8.161	8.977
Diária	5.790	8.161	8.977

Tarefa	LSTM	Transformer	Informer
Mensal de um passo	4.601	8.161	8.977
Mensal de seis passos	4.806	8.161	8.977

Fonte: elaboração própria. Soma das dimensões dos pesos e biases das implementações auditadas, para dez localidades. Buffers não treináveis são excluídos. A contagem é igual nas quatro condições de entrada e nos três regimes temporais.

Transformer e Informer compartilham a projeção de saída entre posições, mantendo suas quantidades em todas as tarefas. A LSTM possui 4.560 + 41H parâmetros por causa da cabeça linear que produz o vetor inteiro. As contagens documentam o tamanho das redes, mas não equalizam sua capacidade efetiva nem demonstram igualdade de custo de treinamento.

C.2 Ambiente das execuções

O ambiente registrado utiliza NumPy 2.4.4, pandas 3.0.3 e PyTorch 2.12.0+cu126. As tarefas horária e diária usam CUDA 12.6; as mensais, CPU. Para Transformer e Informer horários e diários, consta a GPU NVIDIA GeForce GTX 1650 with Max-Q Design e cuDNN 91002. Na LSTM, consta CUDA sem identificação da GPU. O modelo da CPU e a versão de Python não foram registrados. A reprodução também depende das sementes e regras de determinismo descritas na metodologia.